

人工智能与机器学习概述



2025年2月

TRANSWARP
星环科技

目录

CONTENTS

- 1 人工智能基本概念
- 2 人工智能工作流程
- 3 人工智能典型技术方案
- 4 人工智能典型应用场景

The background features a complex network diagram with numerous nodes (small circles) connected by thin lines, forming a web-like structure. The nodes are distributed across the entire frame, with a higher density of connections on the left and right sides, creating a sense of depth and connectivity.

1 chapter

人工智能基本概念


- ✓ 概念介绍
- ✓ 模型分类
- ✓ 各种任务

什么是人工智能？




人工智能（英语：Artificial Intelligence, AI）亦称机器智能，是指利用计算机来对人的意识、思维信息过程、智能行为进行模拟（如学习、推理、思考、规划等）和延伸，使计算机能实现更高层次的应用。

什么是机器学习？



从数据中学习的AI叫做机器学习。机器学习是指从一系列的原始数据中提取人们可以识别的特征，然后通过学习这些特征，最终产生一个模型。

- 机器学习是人工智能的一个实现途径
- 深度学习是机器学习的一种算法



特性	人工智能 (AI)	机器学习 (ML)	数据挖掘 (DM)
定义	模拟人类智能的广泛领域，包含多种技术和方法	从数据中学习并自动改进的技术，AI 的子领域	从大数据中提取有价值的信息和模式
目标	使计算机系统具有人类智能行为	通过数据训练模型，自动做出预测和决策	挖掘隐藏在数据中的趋势和模式
技术范围	推理、自然语言处理、计算机视觉、专家系统等	监督学习、无监督学习、强化学习等	聚类、分类、关联规则挖掘、异常检测等
应用领域	智能助手、自动驾驶、机器人等	模式识别、预测分析、NLP 等	商业分析、金融、市场营销等
方法	包括机器学习、符号推理、搜索算法等	主要依赖统计学算法和学习模型	依赖统计分析、模式识别，常用机器学习方法
依赖关系	AI 包含 ML 和其他技术	ML 是 AI 的一部分	DM 可使用 ML 方法来提取数据中的模式

机器学习是一门致力于研究如何使计算机能够从数据和经验中自动学习的科学学科。它通过运用各种算法来对数据进行分析，从而从已有数据中提取规律，进而构建模型来进行未来的预测。



从买芒果开始讲起



怎么挑芒果才靠谱呢? ...

一开始妈妈告诉你:

“ 金黄色的要比浅黄的更甜些! ”

但买回芒果后，你发现生活没有那么简单...

一番细品，再一番苦想你得出结论：

“那些大个儿的、金黄色的芒果一定是甜的，而那些小个儿的、金黄的就只有一半是甜的了”

于是你再一次来到水果市场...

原来的水果摊关门了换了一家新的，刚总结的经验在这里不适用了，一切从头开始，你尝了一遍后发现：

“那些小个的、浅黄的芒果是当中最甜的”

有一天，你旅游来到了一个新的国家...

这儿的芒果味道与家乡的截然不同：

“ 绿色的竟然要比黄色的味道更棒 ”

作为码农的你，为什么不写一个程序来帮你挑芒果呢...

if 个头= "大" and 颜色= "金黄色" and 产地= "AAA" then 甜度= "★★★★★"

if 个头="小" and 颜色="浅黄色" and 产地="BBB" then 甜度= "★★★★"

if 个头= "小" and 颜色= "绿色" and 产地= "CCC" then 甜度= "★★★"

...

你结婚了，你的另一半不喜欢芒果而喜欢苹果，为了她...


你跑遍了水果店，又得学“神农遍百果”，摸索
苹果的特征和味道之间的关系

想一想，总感觉哪里不对

但是，这个程序也有一个 **麻烦的地方**，你每次遇到一个不符合程序规则的情况，你就要手工的修改一下你的规则，时间久了，你发现规则越来越多，越来越复杂（这就催生了 **规则引擎** 这样的产品），你对芒果如此了解，都可以拿下一个 “**芒果科学家**” 的 title 了（如果有的话^_^）。

怎么办？能不能找到一个更加 **智能** 的挑选芒果的 **算法** 呢？有，那就是 **机器学习**！其实，机器学习就是之前介绍的 **规则算法的进化版**，它能比人肉寻找规则 **更加聪明**，能从数据中 **自动的学到知识**（这是机器学习中的 “**学习**” 的含义）

图不重要
看文字



怎么做呢

你在市场上随机选择了一些 **不同品种的芒果**（我们称之为 **训练样本**），把每个芒果的特征信息都写进如下的一个表格中：包括 **颜色、大小、形状、产地** 等（我们称之为 **特征变量**），当然还有一个最重要的信息，就是每一只芒果你亲自品尝过后的 **甜度**，你可以把它们标记为 **甜和不甜**（这称之为 **目标变量**，这个过程又叫 **数据标记**）。**你把这些数据输入到一个机器学习算法中去，然后这个算法就会自动的帮你找到什么特征的芒果会比较甜**（这就得到了**机器学习模型**）




世界那么大，为什么
最帅的偏偏是我？

写个机器学习算法吧

你在市场上随机选择了一些芒果（training data），把每个芒果的特征都写进了如下表格

产地	颜色	大小	形状	水果市场	甜度
中国	金黄	大	椭圆	人民路	甜
泰国	绿色	大	椭圆	建设路	不甜
马来西亚	浅黄	小	椭圆	人民路	甜



“智能选芒果” 应用上线了，啦啦啦

等你下一次到市场买芒果的时候，你只需要把摊位上的 **芒果特征信息收集** 一下，然后扔进你的 **机器学习模型** 中，它就会 **自动预测** 哪些芒果是甜的。这个机器学习模型可能比之前经验的规则要更加复杂，挑选甜芒果的准确度要更高。例如之前挑选 **100** 个芒果，可能只有 **70** 个是甜的（**70%的准确率**，这就是模型的评估指标 **precision**），而现在用机器学习模型可能有 **90** 个是甜的，准确率达到了 **90%**。更加重要的是，你以后每吃一个芒果，都可以把它的数据添加到模型中进行训练，不断 **迭代升级你的模型**，准确率也会越来越高。**算法还可以在每次预测错误之后进行自我修正**（这就是 **增强学习**），更妙的是，你还能用 **同一个算法来训练不同的模型**，例如预测苹果、橙子、香蕉、葡萄、樱桃、西瓜等等（这就是 **迁移学习**）



这么呀，你家里人知道吗

总结：从示例中我们学到的..... (1/2)

- 我们要挑选“甜”的芒果，即预测芒果的“甜度”，这就是 **机器学习的目标**，“甜”的芒果叫 **正例**，“不甜”的芒果叫 **负例**
- 奶奶告诉你金黄色的芒果都是甜的，其实这就是一个 **最简单的模型**，不过这个模型来源于经验规则，这个模型是 **欠拟合** 的
- 只尝了一家水果店总结出来的甜芒果的规律到另外一家店就不适用了，这就叫模型的 **过拟合**，这是因为机器学习的样本太少，没有找到更 **普适的规律**。
- 你总结出来的挑选芒果的 **if ... then ...** 规则，就是模型的一种表现形式（**基于规则的模型**，例如以后会学到的决策树算法结果就是这样的规则）
- 你采集了大量的芒果的信息并记录成一张表格，这就是机器学习的 **训练样本**，机器学习 **算法** 就是基于这些训练样本来学习找到甜芒果的 **规律**。
- 训练样本中的芒果的一些信息：例如产地，颜色，大小等，这就叫 **特征变量**，机器学习常常提到的 **特征工程** 就是指 **采集这些特征变量** 的过程。如何 **设计和收集** 足够多的特征变量，是决定机器学习预测效果非常重要的因素。



没毛病老铁

总结：从示例中我们学到的..... (2/2)



- 按照模型挑选了你认为甜的 **100** 个芒果，结果吃过之后只有 **70** 个是甜的，**70%** 就是模型预测的 **准确度(precision)**，这是预测模型评估非常重要的一个指标。
- 算法每次在预测错了之后还能进行 **自我修复**，这就是机器学习中的 **增强学习**
- 如果你已经训练好了一个挑选芒果的模型，然后根据数据稍微微调一下就用它来 **挑苹果**，**挑西瓜**，这就是机器学习中的 **迁移学习**
- 当你把挑芒果这件事情做得相当棒了，人人都来找你帮忙挑芒果，你就变成 **芒果领域的数据科学家**了，如果你的模型比其他数据科学家做的模型都好，还掌握了别人不掌握的核心技术，那你就是芒果领域中的 **首席数据科学家**
- 有一天，你成立了一家公司，专门利用你的机器学习模型来帮人挑芒果，你给公司起了一个时髦的 **Slogan** 叫 **人工智能挑芒果**，恭喜你，你进入了时下最时髦的 **AI+创业领域**，赶快融资圈钱吧，发财了别忘了我哦
- ~

你倒是换个套路啊




什么是机器学习?

$$y=f(x)$$

- 语音识别

$f(\text{audio waveform}) = \text{“你好”}$



- 图像识别

$f(\text{cat image}) = \text{“Cat”}$




- Playing Go

$f(\text{Go board state}) = \text{“5-5”}$



- 对话系统


$f(\text{“Hi”}) = \text{“Hello”}$






什么是深度学习?

震撼!!! 深度学习3d展示




推理 时期	1960s	赋予机器逻辑推理能力使机器获得智能；当时的AI程序证明力一些著名的数学定理，但由于缺乏知识，远不能实现真正的智能。
知识 时期	1970s	将人类的知识总结出来教给机器使机器获得智能；即“专家系统”，在很多领域获得大量进展，但由于人类知识量巨大，故出现“知识工程瓶颈”。
机器学 习时期	1980s	连接主义较为流行；代表方法为神经网络。
	1990s	统计学习占据舞台。代表方法包括支持向量机等。
	21Cent.	深度神经网络被提出，连接主义卷土重来。随着数据量和计算能力的不断提升，以深度学习为基础的诸多AI应用逐渐成熟。

AI的架构



AI的架构



AI技术架构


- 业界普遍将其分为三层架构，从底向上依次是**基础层、技术层、和应用层**
- 在基础层，主要提供了**强大的计算能力**和**丰富的数据资源**，其技术方向已经从原来基于传统数据库的集中式存储演变成为现在的基于大数据的**分布式存储**，提供了丰富的高质量数据资源，并且基于云计算技术提供了强大的分布式计算能力，为上层的**技术层和应用层**提供了可靠的基础保障。拥有了数据资源和计算能力之后，就需要有特定的技术来处理这些数据
- 在技术层，提供了丰富的**计算学习算法**和**运行库**，以及丰富的建模能力，以保证数据能在这一层得到充分的加工和处理。

AI项目应用


- 当基于数据和机器学习算法训练出来一个模型之后，怎么发挥其价值呢？自然需要不同领域的业务系统来做支撑。
- 在应用层，我们需要结合不同行业、不同领域的特定业务知识，然后基于丰富的数据源和建模平台来训练高效的模型，并且以应用系统的形式展现给用户，发挥其业务价值。
- 基于上述的三层架构，我们可以将人工智能项目的建设过程分为以下几个阶段：可以在基础层实现的**数据收集、数据理解和数据处理**，可以在技术层实现的**特征提取、模型构建、模型训练和模型评估**，最后可以在应用层实现的**模型应用**等。




生物识别的通用流程



下图一个典型的对开门进行人脸识别的案例。






机器学习算法-传统&非传统


- 常见的机器学习算法主要分为两大阵营，包括**传统机器学习**和**非传统机器学习**，传统机器学习主要应对的是**结构化数据**和**业务相对不是很复杂的场景**，比如房价预测，流失预警。而非传统机器学习主要是应对的是**结构化以及非结构化数据**和一些传统机器学习算法难以解决的场景。比如**图像识别、自然语言处理**等。
- 而传统机器学习算法进一步细分为**监督学习算法**和**非监督学习算法**。常见的监督学习算法包括**分类、回归、时间序列**等算法，非监督学习算法包括**聚类、异常检测**等。
- 非传统机器学习算法，也称之为高级算法，主要是以传统机器学习算法为基础衍生得来的，比如，**强化学习、迁移学习和深度学习**，逐渐在一些复杂的业务场景下扮演着越来越重要的角色。

机器学习，核心在“**学习**”两个字上，机器是如何“学习”的呢？一般来说有四种学习模式：



监督学习 (Supervised learning)

所谓的监督，简单的理解就是算法在学习过程需要**指定目标**来进行学习（例如需要知道训练样本中的每一个芒果是甜的还是不甜）。就好比我们已经知道了题库中每道题目的正确答案，然后对所有这些题进行学习。当我们学到了解题方法之后，对不在题库中的题目进行解答，最终验证我们的学习效果如何。



监督学习


监督学习是机器学习中最常见和最重要的一种学习方式。监督学习主要用来解决预测性问题，最常用的算法有如下：

1. **K 近邻(K-Nearest Neighbors, KNN)**：根据 K 个最近邻样本的类别来确定未知样本的类别，用于分类任务，如手写数字识别。
2. **线性回归(Linear Regression)**：通过拟合一条直线，使预测值与实际值的差距最小，用于预测连续值，如房价预测。
3. **逻辑回归 (Logistic Regression)**：使用 sigmoid 函数将线性回归结果映射到概率值，用于二分类问题，如垃圾邮件识别。
4. **支持向量机 (Support Vector Machine, SVM)**：寻找超平面以最大化不同类别之间的间隔，可用于分类和回归，擅长处理高维数据。
5. **朴素贝叶斯 (Naive Bayes)**：基于贝叶斯定理和特征独立假设，通过计算概率进行分类，常用于文本分类和情感分析。
6. **决策树 (Decision Tree)**：以树形结构进行决策，每个节点代表一个特征，每个分支代表一个决策规则，可用于分类和回归，如客户流失预测。
7. **随机森林 (Random Forests)**：构建多个决策树并综合其结果进行决策，降低过拟合风险，用于分类和回归，如预测信用风险。
8. **神经网络 (Neural Network)**：模仿人脑神经元结构，通过多层次神经元传递和处理信息，用于复杂的模式识别和数据拟合，如图像识别和自然语言处理。


监督学习

监督学习一般分为：**回归问题**和**分类问题**

北京市六环外某小区房价预测模型



肿瘤良性\恶性预测



非监督学习

顾名思义，非监督学习就是一种**无目标的学习**。你可能会会有很多疑问：无目标是什么意思？没有目标那机器学出来的东西是什么？有用吗？其实这里说的无目标是相对监督学习的有目标来说的，指的是学习过程中没有目标变量的监督，但并不是说非监督学习是没有目的的乱学。其实不同的非监督学习算法都是有各自的目的的，例如聚类分析，它的目的就是去发现结构，找到相似的数据把它们聚为一类。之所以说聚类是非监督学习，就是因为到底聚多少个类，这个是需要算法自己去探索的。**非监督学习就好比给了你一本书，让你去自学，从中找到一些规律。**



非监督学习

非监督学习算法常用于对**数据进行探索性分析**，例如 **聚类，降维，异常检测，寻找关联性** 等。另外，监督学习和非监督学习并非完全独立，有时候我们会**把非监督学习的输出作为监督学习算法的输入**，往往会产生比较好的预测效果。常用的非监督学习算法有：

1. **K 均值聚类 (K-Means Clustering)**：将数据分成 K 个簇，每个簇由所有距离该簇中心点最近的数据点组成。
2. **基于密度的聚类方法 (DBSCAN)**：根据数据点的局部密度来识别具有相似密度区域的簇。
3. **主成分分析 (PCA)**：通过线性变换将高维数据投影到低维空间，同时尽可能保留原始数据的方差。
4. **自组织映射神经网络 (SOM)**：模仿人类大脑神经元的自组织特性，将高维数据映射到低维空间。
5. **受限玻尔兹曼机 (RBM)**：由可见层和隐藏层组成的生成式随机神经网络，用于学习数据的概率分布。
6. **孤立森林 (Isolation Forest)**：通过随机选择特征和分裂值来隔离异常点，从而进行异常检测。

半监督学习 (Semi-supervised Learning)

- 训练集同时包含有标记样本数据和未标记样本数据。
- 半监督学习的方式，既用到了标签数据，又用到了非标签数据。




强化学习

强化学习不同于监督学习和非监督学习。在强化学习中没有原始数据输入让算法来学习。强化学习面对的是一个不断变化的状态空间，要解决的是一个**决策链问题(马尔可夫决策)**。其目的是找到在当前状态下的最佳决策是什么。这里的挑战是，当下的决策好坏当下无法验证和评估，要根据多次决策以后才能知道。就像下棋，当前的决策（落子）要在五步十步棋之后才能判断是好还是坏。所以强化学习中并没有大量的原始数据输入，机器需要在不断变化的环境中通过大量的**试错学习**，再根据某种规则找到产生最佳结果的路径，从而做出**最佳决策**。

强化学习

强化学习最经典成功案例就是 **AlphaGo**，此外强化学习主要用于：玩游戏、机器人、自动驾驶 等领域。你可以考虑利用强化学习算法来学玩微信的小游戏“跳一跳”，一开始不需要准备什么数据，就是让程序不停的玩，每跳一次“死”了就**惩罚**，“不死”就**奖励**，用不了多久你的程序就可以做到怎么跳都不会“死”了



机器学习要解决的任务

机器学习并不是简单的玩数学游戏，它是能真刀真枪的解决很多实际问题的。简单归纳总结一下，机器学习主要解决六大类问题：

- (1) 分类问题
- (2) 聚类问题
- (3) 回归问题
- (4) 关联问题
- (5) 序列问题
- (6) 异常检测问题



分类问题 (Classification)

多分类和多标签分类

今日头条

首页

军事 /

正文

多分类



6012

47岁的大校为陪家人退役，并选择自主择业

[原创] 政知道 2017-08-10 08:27



微博

撰文 | 李岩 编辑 | 周宇

1、文本多分类

知乎

首页

发现

话题

搜索你感兴趣的内容...



提问

多标签分类

机器学习

文本分类

分类算法

深度学习 (Deep Learning)

word2vec

如何评价Word2Vec作者提出的fastText算法？深度学习是否在文本分类等简单任务上没有优势？

Word2Vec作者Mikolov在预印本 (Bag of Tricks for Efficient Text Classification, [arxiv...](#)显示全部)


1 条评论 分享 邀请回答 举报 ...

2、文本多标签分类

分类问题 (Classification)

如下的这些问题都属于分类问题：

- **垃圾邮件识别**：判断一封邮件是否是垃圾邮件
- **文本分类**：判断一篇文章属于什么类型（例如体育类，财经类，娱乐类...）
- **信用评分**：判断申请者的信用好坏决定是否放贷
- **欺诈检测**：检测信用卡的刷卡消费是否是欺诈行为
- **图像分类识别**：识别图片中的动物是猫还是狗
- **用户流失预测**：预测用户下一个月是否会流失
- **营销响应预测**：预测用户对营销活动是否会响应
- **广告点击率预估**：预测用户对广告是否会点击
- **商品推荐**：预测用户对推荐的商品是否有兴趣
-



回归问题 (Regression)



1000



?

回归问题 (Regression)


常见的回归问题有：

- 房价预测：根据房子的各种特征来预估房子的价格
- 销量预测：根据商品的相关特征来预测商品的销量



聚类问题 (Clustering)

“物以类聚，人以群分”，这就是聚类，它的目的就是要将相似的数据聚在一起。例如通信运营商可以对手机用户的 **通话行为** 进行聚类，把 **喜欢上网** 的聚类一类，**喜欢夜间打电话** 的聚为另外一类。你也可以对大量的文章进行聚类，把 **相似的文章聚为一类** 然后归到同一个文件夹中。聚类问题属于非监督学习的范畴。



聚类问题 (Clustering)

常见的聚类问题有：

- **用户分群**：企业对用户的消费行为进行聚类，把用户划分为不同的人群，然后对用户进行差异化的服务。
- **相似文档归类**：对大量的文档进行聚类分析后，把文档分为若干个不同的类

注意：聚类和分类都有一个“类”字，但是它们有显著的差别：

- **分类问题的“类”就是训练样本的标签**，这个标签是训练模型之前需要**事先标记好的**，分类算法的目标是建立一个对标签进行预测的模型；
- 而聚类的“类”，是聚类算法需要对数据进行学习之后才能得到的结果，在训练模型之前我们是**不知道样本的类标签**的。

关联问题 (Association Rule)

关联问题最有名的案例就是啤酒和尿布的故事。关联规则算法可以从交易型数据中发现频繁关联出现的 Item (商品)，又称为**购物篮分析**和**关联规则挖掘**。关联规则挖掘属于非监督学习的范畴。

常见的关联问题有：

- 商品买了还买：买了 A 商品的人，同时还有多少比例会购买 B, C, D, E...
- 电影看了还看：看了电影 A 的人，同时还有多少比例会看电影 B, C, D, E...




序列问题 (Sequence)

- 序列问题包括 **时间序列** 的预测, **序列型关联** 规则 (例如先看了速度与激情 1, 接下来看速度与激情 2 的可能性比较大) 等。
- **语言模型** (哪些词经常可以搭配在一起) 也属于序列问题。
- 序列问题既可以 **是非监督学习的方法** (类似关联规则算法), 也可以转换为回归, 分类等 **监督学习** 的问题。

常见的序列问题有:

- 用户**购物模型**预测: 根据之前购买的商品序列预测接下来可能会买的商品
- 时间序列预测: 例如**预测股票**, **预测天气**等
- **中文分词**: 判断哪些字组合在一起最可能像一个词语




异常检测问题 (Outlier Detection)

异常检测就是检测样本取值是否显著的偏离常规，从中发现有意义的 **孤立点** 和 **异常值**。 **监督学习** 和 **非监督学习** 都可以应用于异常检测问题。

常见的异常检测问题有：

- 信用卡异常消费检测（欺诈检测）
- 网络安全检测
- 不合格产品检测




Question?

有参模型

- 假设数据服从某种分布(高斯分布等)
- 模型参数**不随**数据量增加而增加
- 模型**简单**,计算量**小**


无参模型

- **不假设**数据服从任何分布
- 模型参数**随**数据量增加而增加
- 模型**复杂**,计算量**大**



机器学习本质


- 假设我们有训练数据 (X,Y) ， X 是属性集合， Y 是类别标记。这时来了一个新的样本 a ，我们想要预测它的类别 b 。
- 我们最终的目的是求得**最大的条件概率** $P(b|a)$ 作为新样本的分类标签。
- 简单地说，**判别式模型**是针对**条件分布**建模，而**生成式模型**则针对**联合分布**进行建模。


$$P(A|B) = \frac{P(B|A) P(A)}{P(B)}$$

判别式模型

- 直接对条件概率分布 $P(y|x)$ 建模
- 根据训练数据得到分类函数和分界面,然后直接计算条件概率 $P(y|x)$, 我们将最大的 $P(y|x)$ 作为新样本的分类

$$\sum_y P(y|x) = 1$$




生成式模型

- 先对联合概率分布 $P(x, y)$ 建模, 然后利用贝叶斯公式转换成 $P(y | x)$

$$\sum_y P(x, y) = 1$$

$$P(y|x) = \frac{P(x, y)}{P(x)}$$



Question?

The background features a complex network of thin grey lines connecting small grey dots, forming a spherical shape on the left and right sides of the slide. In the center, there is a dark blue circle containing the number '2' in white, with the word 'chapter' in white lowercase letters below it.

2 chapter

人工智能工作流程

- ✓ 业务沟通与业务目标确认
- ✓ 业务问题转换为机器学习问题
- ✓ 常规建模流程
- ✓ 模型/业务解释



甲方乙方

对于在人工智能项目中，需要明确自身的角色，即**甲方**还是**乙方**，不同的角色需求不一样，要求不一样。对于甲方，需要专注于自身的业务，在充分理解业务的同时提出合理的需求，并且需要做好合理的时间规划。对于乙方，需要在充分理解甲方业务需求的条件下，结合自身的实际情况做出合理且符合实际的评估。在项目进行的过程中，甲方乙方需要反复的沟通，不断确认业务目标，确保每一步的进展都和预期的偏差不大。


没有银弹算法，具体问题，具体分析！




沟通与确认

在和客户进行业务沟通的时候一般从以下三个方面进行入手，包括**数据与目标**、**做法与思路**、**应用与评估**。具体包括客户现在有哪些数据，想基于这些数据做什么事情，这个项目开始之前是怎么做的，是改进原有的系统还是新需求，之前系统的结果有什么不满意的地方需要改进和完善，当前的问題能不能用机器学习的方法来做，如果能做的话，怎么把业务问題转化为机器学习问題，如果能转化为机器学习问題的话，他们的优先级是什么样的，哪个需求是基础需求需要优先来做，哪个需求是高级需求，需要在项目二期来做，训练出来的模型用在什么系统上，怎么用，测试数据的形式是什么样子，期望达到什么效果，包括机器学习模型评估的效果和业务上达到的效果。

- 在真正用人工智能技术解决真实业务问题之前，需要仔细回答以下问题：





人工智能建模流程

- 人工智能建模流程一般需要分为以下三个阶段，包括**数据处理**阶段、**模型训练**阶段和**模型应用**阶段。
- 在数据处理阶段，首先我们需要进行数据获取，一般数据获取发生在项目初期，这时候相对比较容易一些，所以我们需要**尽可能的多获取一些数据**，一方面防止以需要用一些数据的时候没有数据的不利情况。另一方面，在项目已经全面开展的时候再跟客户申请数据会**比较麻烦**，同时申请流程也会比较复杂，会严重影响项目进度。在获得比较多数据之后，需要充分理解业务和需求确认，确定哪些数据可用，哪些数据作为后期补充，同时需要评估数据质量和业务复杂度来合理规划项目周期。
- 以上工作做完以后，就可以开始结合数据的实际情况进行数据清洗，以提升数据质量，具体数据怎么清洗，怎么预处理，我们再后面的课程会详细介绍。

特征工程 -> 模型部署上线

- 我们需要进行特征提取，也就是所谓的**特征工程**，需要基于原始数据提取人们可以识别的衍生特征，提升训练的模型效果，最后需要将加工的不同维度的特征进行整合形成一张**大宽表**，为下一步的模型训练做准备。至此，我们的数据预处理阶段就告一段落。
- 接下来，我们需要对之前加工的特征进行描述，评估其**权重**，必要的时候进行**特征降维**，之后结合具体的业务问题，选择一个或者几个机器学习算法，通过不断**调整参数**反复训练模型，直到模型效果达到预期为止，之后要加载测试数据进行测试，防止发生过拟合问题而全然不知的情况。
- 在模型经过评估且效果能达到预期之后，我们需要将模型进行**部署上线**，并且对与线上的测试结果结合业务部门进行业务解释，看是否能达到业务部门的目标，以及确认模型的迭代方式和迭代周期。至此，整个项目周期算是初步结束了，后面就剩下了模型迭代和系统维护工作了。

		真实结果	
		流失1	未流失0
预测结果	流失1	流失且预测为流失 TP	未流失却预测为流失 FP
	未流失0	流失却预测为未流失 FN	未流失预测为未流失 TN

准确率

$$\frac{TP}{TP + FP} = \frac{\text{真实流失且预测为流失客户}}{\text{所有预测为流失客户}}$$

召回率

$$\frac{TP}{TP + FN} = \frac{\text{真实流失且预测为流失客户}}{\text{所有真实为流失客户}}$$






3 chapter

人工智能典型技术方案

- ✓ 星环人工智能解决方案
- ✓ 其他技术方案




星环人工智能解决方案


在人工智能方面，星环提供了一个完整的解决方案，涵盖了我们之前提到的基础层和技术层。在基础层，星环提供的云平台TDC能很好的满足技术层对计算资源的需求和调度。另外，在大数据平台中提供的丰富数仓能满足技术层对各种数据源的需求。在技术层，星环提供的sophon人工智能平台，集成了多种计算框架，分布式机器学习算法以及常见算法运行库，能满足用户多种多样的建模需求。在此基础上，会结合不同行业，不同领域对应不同的业务子模块，比如互联网模块、知识图谱模块、图像识别模块等。同时，提供的一些高级模块，能够满足用于对模型管理、特征管理以及服务管理的特殊需求。


4.1 星环：Sophon用户界面

人工智能技术方案



Azure Machine Learning






The background features a complex network diagram with numerous nodes (dots) and connecting lines, forming a spherical shape on the left and right sides of the slide. The nodes are of varying sizes and are connected by thin, light gray lines, creating a web-like structure.

4 chapter

人工智能应用场景

✓ 典型应用场景

基于关联分析的案例：沃尔玛的啤酒尿布



关联分析-啤酒与尿布

说起人工智能的应用场景，相信大家对这个啤酒与尿布的故事不会太陌生，其实找个故事是一个典型的超市购物篮分析案例，用的是典型的关联分析算法。当然“啤酒与尿布”的故事必须具有技术方面的支持。1993年美国学者**艾格拉沃（Agrawal）** 提出通过分析购物篮中的商品集合，从而找出商品之间关联关系的关联算法，并根据商品之间的关系，找出客户的购买行为。艾格拉沃从数学及计算机算法角度提出了商品关联关系的计算方法——**Aprior** 算法。沃尔玛从上世纪90年代尝试将 **Aprior** 算法引入到 **PoS** 机数据分析中，并获得了成功，于是产生了“啤酒与尿布”的故事，最终由于啤酒和尿布关联性比较高，放在相邻的货架进行出售，两者销量都有所提升。

美国零售连锁超市 Target 和怀孕预测指数



回归预测-迟来的道歉

回归预测，既用一系列特征来预测一个连续的结果，比如房价预测、交通流量预测等。故事是这样的，美国一名男子闯入她家附近的一家美国零售连锁超市 Target 店铺（美国第三大零售商塔吉特）进行抗议：“**你们竟然给我 17 岁的女儿发婴儿尿片和童车的优惠券。**” 店铺经理立刻向来者承认错误，但是其实经理并不知道这一行为是总公司运行数据挖掘的结果。一个月后，这位父亲来道歉，因为这时他才知道他的女儿的确怀孕了。Target 比这位父亲知道他女儿怀孕的时间足足早了一个月。

Target 能够通过分析女性客户购买记录，“猜出”哪些是孕妇。他们从 Target 的数据仓库中挖掘出 **25** 项与怀孕高度相关的商品，制作“**怀孕预测**”指数。比如他们发现女性会在怀孕四个月左右，大量购买无香味乳液。以此为依据推算出预产期后，就抢先一步将孕妇装、婴儿床等折扣券寄给客户来吸引客户购买。

这是一个**怀孕指数预测模型**，也是一个典型的回归预测模型，用来预测每一位女生用户的怀孕指数，而这个怀孕指数（可能性）是一个连续的值。

基于社会网络分析团伙反欺诈



基于社会网络分析团伙反欺诈

在一些特殊的应用场景，比如团伙反欺诈、反洗钱、社交网络分析等，经常要使用一种称之为**图关系**的数据作为模型训练的特征。如果我们学过数据结构这门课，应该清楚，有一种数据结构叫做**图**，**图是由点和边构成，边分为有向边和无向边，图中有出度、入度和中心度的特征**，常见的图算法有社区发现算法，最短路径算法等。基于这些图的基础知识，我们可以在一些特殊的场景下构造图关系来丰富模型训练的特征，比如在团伙反欺诈中，我们通过分析用户使用的手机号和经常所在的IP网段的图关系，来分析这些人是不是一个团伙；用手机号和设备唯一识别号的图关系来分析这个人是不是经常更换设备，是不是有异常行为等。

同时，图分析在社交网络中也有这颇为广泛的应用，比如领英、脉脉、QQ可能认识的人推荐等。

文学著作与统计：红楼梦归属



自然语言处理 - 解答红楼梦作者归属

有一个非常著名的争论，悬而未决。对于红楼梦的作者，通常认为是前80回合是**曹雪芹**所著，后40回合为**高鹗**所写。其实主要问题，就是是否能确定，前后是否存在遣词造句方面是否有明显差异。因为每个人在写作上的习惯是不同的。

这种概念被提出来之后，让一群统计学家比较兴奋。有些学者通过统计**名词、动词、形容词、副词、虚词**出现的频次，以及不同词性之间的相关关系做判断。有些学者通过虚词（例如之、其、或、亦、了、的、不、把、别、好），判断前后文风的差异。有些学者通过场景（花卉、树木、饮食、医药与诗词）频次的差异，来做统计判断。总而言之，主要通过一些指标量化，然后比较指标之间是否存在显著差异，藉此进行写作风格的判断。

然而如果引用人工智能的**自然语言处理（NLP）**技术，可以轻易实现那些学者的需求，能够以比较客观的方式解决红楼梦的归属问题。

京东金融JDD大赛：猪脸识别

猪脸识别

[立即登录](#)

商业组 · 比赛进行中 · 当前参赛人数 139 人 · 比赛截止日期 2017-12-17

[赛事介绍](#)[赛题与数据](#)[常见问题](#)[排行榜](#)[提交结果](#)

赛题概要

身份识别是目前图像算法领域的重要问题之一，有着广泛的应用领域，如快捷支付，登录验证，安防监控等，猪的身份识别当然也非常重要。

赛题背景

家住北京周边的养猪专业户老张最近遇见了一个难题，经过多年辛苦的劳动与努力，他家的养猪场规模越来越大，猪的数量从原来的几头发展到现在的上百头。看着这么多的肥猪老张心里美滋滋的。但伴随着猪数量的增长，愁人的问题也随之而来，这么多的猪体型都很相近，老张想要清晰的分辨出每头猪变得越来越困难。

赛题内容


本题目要求参赛者设计一个算法，能够通过猪的照片来正确的辨别每一头猪的身份。

深度学习-猪脸识别

大家可能听说过人脸识别，那么有谁听说过猪脸识别吗？在京东金融2017年的建模比赛中提出了这么一个赛题：**猪脸识别**。

我们现在解释一下这个概念，“猪脸识别”技术，是生物活体识别的一种，具有广泛的应用前景，不仅可以用来识别猪，还可以实现对牛、羊等动物，甚至是狗狗的识别，不但能够帮助养殖场对每一头猪进行跟踪，实现日常信息管理与全流程追溯，而且该技术还能通过“猪脸识别”来实现农村金融养殖保险的革新、数据农贷的开展，让农民能用上金融工具来更好的开展养殖生产；而且在未来，“猪脸识别”有望实现通过对动物面部特征、体态的识别来判断猪的品种，通过对猪体态和动作的识别来判断猪的健康情况。

电子竞技-AI dota



AI 选手训练量惊人，相对于每天可打 200 万局 dota

256 块 GPU 12.8 万个 GPU 核心



Q&A

TRANSWARP
星环科技