

数据准备与数据处理



2025年2月

TRANSWARP
星环科技

目录 >

CONTENTS

- 1 建模流程回顾
- 2 数据理解
- 3 单变量数据探索
- 4 多变量数据探索
- 5 数据预处理
- 6 特征变量的构造和组合

为什么要学习数据处理？

就像你每天醒来第一件事情是睁开眼睛一样，做机器学习第一件事情就是 **理解数据，数据是机器学习之本**，没有数据再好的算法也出不来效果。人工智能工作者达 **80%** 左右的时间在 **数据的获取、清洗、转换与处理及特征工程的提取** 上，人工智能行业流传这么一句话：**数据决定了模型的上限，算法只不过是无限逼近这个上限而已**，其重要性，可见一斑。本次课，我们将一步步带你进入 **数据处理与特征工程** 的专业领域！


学完本次课后，我们主要要搞清楚数据处理的常见处理方法：

- 数据读取
- 单变量探索分析
- 多变量探索分析
- 数据预处理
- 缺失值处理
- 独热编码
- 分箱
- 标准化和归一化
- 变量构造和组合

- <https://github.com/ForceInjection/hands-on-ML>
- [Kaggle入门：逻辑回归应用之Kaggle泰坦尼克之灾](#)

1
chapter

建模流程回顾



The background of the slide features a complex network diagram. It consists of numerous small, dark grey circular nodes connected by thin, light grey lines. These connections form a dense web of triangles and other geometric shapes, creating a sense of interconnectedness and data flow. The overall aesthetic is clean and modern, typical of data science or technology presentations.

2 chapter

数据理解

- ✓ 任务分析
- ✓ 查看数据



著名的数据科学竞赛平台 **Kaggle** 上有一个非常适合机器学习练手的赛题叫泰坦尼克号**幸存者预测**分析，我们接下来的知识点都以这个案例来贯穿讲解。

比赛提供了 **891** 名泰坦尼克号的乘客数据，包含乘客的姓名，性别，年龄，客舱等级等信息，当然还有一个最重要的信息是：**乘客是否生还**（它有两个取值：**1 表示生还，0 表示遇难**）。比赛的目标是通过对训练数据集的学习来构建一个分类预测模型，对测试数据集中的 **418** 名乘客 **生存情况** 进行预测。



在**数据理解**环节，我们主要要搞清楚几件事情：


- 机器学习的**任务**是什么？是**监督学习**还是**非监督学习**？是六大类**任务**中的哪一类？
- 数据的**存储格式**是什么？是 csv 文件还是其他格式？
- 每一个**字段**的含义和描述；
- 每一个字段的变量类型：**数值型**还是**类别型**？
- 数据的**规模**：有多少行多少列？
- 数据的**质量**：有多少**缺失数据**？多少**重复记录**？



很明显，这属于一个 **监督学习** 的问题，目标变量是乘客是否生还，由于 **目标变量** 只有 2 个标签值（**0** 或者**1**），所以这个问题是典型的分类问题，准确来说是一个 **二分类** 问题。虽然任务的目标是构建一个分类模型预测乘客的生存概率，但是在建模过程中，我们依然**需要去理解泰坦尼克号幸存者到底有什么样的特征**，这是本章的重点，关于如何构建一个分类模型，我们将在下一章再来介绍。



sophon操作



明细表

图形探索

序号	PassengerId int feature	Survived int feature	Pclass int feature	Name string feature	Sex string feature	Age int feature	SibSp int feature	Parch int feature	Ticket string feature	Fare double feature	Cabin string feature	Embarked string feature
1	1	0	3	Braund, Mr. Owen...	male	22	1	0	A/5 21171	7.25	NULL	S
2	2	1	1	Cumings, Mrs. J...	female	38	1	0	PC 17599	71.2833	C85	C
3	3	1	3	Heikkinen, Miss. ...	female	26	0	0	STON/O2. 3101...	7.925	NULL	S
4	4	1	1	Futrelle, Mrs. Ja...	female	35	1	0	113803	53.10	C123	S
5	5	0	3	Allen, Mr. Willia...	male	35	0	0	373450	8.05	NULL	S
6	6	0	3	Moran, Mr. James	male	NULL	0	0	330877	8.4583	NULL	Q
7	7	0	1	McCarthy, Mr. Ti...	male	54	0	0	17463	51.8625	E46	S
9	8	0	3	Palsson, Master....	male	2	3	1	349909	21.075	NULL	S

名称

titanic_train

描述

无

元信息


列名	注释
Passeng...	
Survived	
Pclass	
Name	
Sex	
Age	
SibSp	
Parch	
Ticket	
Fare	
Cabin	
Embarked	

数据集总共有 12 个变量，每一个变量的名称和含义如下

- PassengerId: 乘客 ID
- Survived: 是否生存
- Pclass: 客舱等级
- Name: 乘客姓名
- Sex: 性别
- Age: 年龄
- SibSp: 在船兄弟姐妹数/配偶数
- Parch: 在船父母数/子女数
- Ticket: 船票编号
- Fare: 船票价格
- Cabin: 客舱号
- Embarked: 登船港口

删除不想要的列

如果你觉得某些变量对后续分析**完全没有意义**，你可以把它删除掉。



筛选类型

subset

额外列

PassengerId, Name

☒ 反向选择

预处理

交互式预处理

清理

字符串

数值

日期

元信息

分桶

属性

高势集特征编码

选择属性

笛卡尔积

DCT

行归一化 (向量单位化)

3
chapter



单变量数据探索

顾名思义，**单变量数据探索就是每次只对 1 个变量进行分析**，相对的，多变量数据探索就是同时分析多个变量之间的相关性。**单变量数据探索主要目的是对单个变量的数据分布进行查看，以方便后续的数据预处理**，常用的单变量分析方法有：

- **频数分析**：分析类别型变量每一个值出现的频数，还可以通过饼图或者**柱形图**的方式可视化展现。
- **直方图 (histogram)**：对数值型变量进行分段处理后进行频数分析并作图，我们经常说的某一个变量服从倒钟型分布（即中间多，两头少），它就是典型的一种直方图分析方法
- **描述性统计**：对数值型变量的常用统计量进行分析：**均值，总和，最小值，最大值，分位数**（如 25 分位，中位，75 分位）。

频数分析适用于**类别型变量**，数据集中的 **Survived**（是否生还），**Pclass**（客舱等级），**Sex**（性别），**Cabin**（客舱号），**Embarked**（登船港口）等变量都是类别型变量，所以可以对他们进行频数分析。



Survived (是否生还) 频数分析



结论：从频数分析结果来看，训练样本中，有 38%的乘客生还了。


Pclass (客舱等级) 频数分析

结论：从客舱等级的频数分析结果可以看到：3 等舱的乘客最多，占了 55%，1 等舱占了 24%，2 等舱占了 21%。



直方图 (Histogram)

直方图用于查看连续型变量的取值分布情况



结论：从 Age 的直方图可以看到：年龄分布呈现中间高，两头低的状态，乘客的主要年龄集中在 **20-30** 之间。上图的直方图把 Age 划分为 50 个区间，对应 50 个柱子，你也可以理解为先对 50 个区间做了频数分析，然后用柱形图对频数进行呈现

描述性统计

描述性统计就是指计算数值型变量的常用统计量，例如：**均值，方差，最小值，最大值，分位数**等，目的也是为了更好的了解变量的分布情况。**对所有数值型变量进行描述统计**
使用 pandas 数据对象的 **describe()**方法，该方法默认出如下统计量：

- count: 非空值频数
- mean: 均值
- std: 标准差
- min: 最小值
- 25%: 25%分位数，又叫下四分位数
- 50%: 50%分位数，又叫中位数(median)
- 75%: 75%分位数，又叫上四分位数
- max: 最大值

4
chapter

多变量数据探索

多变量数据探索 不是说一次性探索多个**单变量**的意思，而是 **同时探索多个变量之间的相关关系**。最简单的多变量探索就是分析 2 个变量之间的相关性。

在单变量探索的时候，我们已经了解到不同类型的变量探索方法是不一样的，例如 **类别型变量适合做频数统计**，而 **数值型变量适合做描述性分析**。同样的，两个变量之间的相关性分析，也要区分不同的变量类型：

- **两个数值型变量** 之间的相关性方法方法：适合用 **散点图/皮尔逊相关性/斯皮尔曼相关性**
- **两个类别型变量** 之间的相关性分析方法：适合用 **交叉表 (crosstab) /堆栈条图/卡方分析/互信息**
- **一个数值型** 变量，**一个类别型** 变量分析方法：适合用 **分类汇总(groupby)统计/方差分析**

大多数情况下，两个变量的相关性分析，一个变量会作为 **自变量 x** ，另外一个变量会作为 **目标变量（因变量） y** 。在本案例中的目标变量（是否生还）是一个类别型变量，为了能演示两个数值型变量的相关性分析，所以我们不能挑选目标变量来分析，只能挑选两个数值型的自变量来做一个演示。我们就挑选 **Age(年龄)**和 **Fare(船票价格)** 两个变量

结论：很明显，从散点图可以看到：船票价格和年龄之间并没有很强的相关性


目标变量 终于要登场了，通过对每一个 **自变量** 与 **目标变量** 的相关性分析，我们可以知道哪些特征与是否生还的相关性最强。

Pclass	1	2	3
Survived			
0	0.145719	0.176685	0.677596
1	0.397661	0.254386	0.347953

结论：

- 1 等舱的生还率是 62.96%,
- 2 等舱的生还率是 47.28%,
- 3 等舱的生还率是 24.23%

说明不同船舱等级的生还率差异很大。





- **分析目标：**我们来分析 **Age** 年龄，**Fare** 船票价格与目标变量的 **Survived** 之间的相关性。
- **分析方法：**使用的方法是对 **Survived** 进行汇总（group by Survived），然后统计**生还**和**未生还**两类乘客的 **Age 均值差异**。

```
1 # 多变量分析：类别变量和数值变量的相关性分析
2 # 按 Survived 汇总，求 Age 和 Fare 的均值
3 titanic_df.groupby('Survived').agg({'Age': 'mean', 'Fare': 'mean'})
```

	Age	Fare
Survived		
0	30.626179	22.117887
1	28.343690	48.395408

结论：生还和未生还的 Age 差异不算大，但是票价差异很大，生还乘客的票价要显著高于未生还乘客，这是可以理解的，因为生还乘客中 1 等舱比例较多。





5 chapter

数据预处理

- ✓ 缺失值处理
- ✓ onehot编码
- ✓ 分箱
- ✓ 标准化和归一化

数据预处理的主要目的是为机器学习建模进行数据准备，数据准备的好与坏对模型效果影响比较大。经常做的一些数据预处理工作有：

- 对**缺失值**的处理
- 对类别型变量的值进行**独热编码(onehot)**
- 把连续型变量进行**分箱**，然后再按照处理类别型变量的方式重新编码
- 对连续型变量进行**标准化和归一化**处理

注意事项：以上的预处理工作并不是对所有问题都是必须要做的，**不同的算法和问题，对预处理的要求是不一样的**，如：


- 缺失值对所有算法来说基本上都要处理
- 连续型变量是否要分箱要看具体算法，决策树算法就不需要
- 而标准化和归一化在涉及到**距离计算**的算法中一定要处理，例如 KNN，聚类分析等

缺失值处理

有三种常用缺失值处理方法：

- 简单粗暴，直接把有缺失值的 **整条记录删除**。这种方法适合 **数据样本较大而缺失记录较少** 的场景，删除缺失记录对整体影响很小。
- 构造一个 **新变量来标记** 缺失值：**缺失就标记为 1，不缺失就标记为 0**。这种方法认为缺失值本身是一个有意义的信息，不能简单处理掉，必须要标记出来。
- 用 **一个值替换掉缺失值**，具体用什么值来替换这个方法也比较多，例如对数值型变量可以考虑用 **均值**，对类别型变量用频数最大的那个值（**众数**）。

删除缺失记录



问题：删除后只有 183 条记录了，原来可是有 891 条记录啊，显然这样做不行啊。

使用sophon进行删除缺失值和替换缺失值

The screenshot displays the Sopion data preprocessing interface, which is organized into several panels:

- Left Panel (Navigation):** Contains a vertical menu with icons and labels. The '预处理' (Preprocessing) option is highlighted with a red box. Below it, the '交互式预处理' (Interactive Preprocessing) section includes '清理' (Cleaning), '替换缺失值' (Replace Missing Values), and '过滤' (Filter), all of which are also highlighted with red boxes. Other options include '导入导出' (Import/Export), '流处理' (Stream Processing), '去重' (Deduplicate), '筛选低质量列' (Select Low Quality Columns), 'DoubleMAD (新版)' (DoubleMAD (New Version)), and '替换异常值' (Replace Outliers).
- Canvas:** A central workspace with a grid background. It contains two draggable operator nodes: '替换缺失值' (Replace Missing Values) and '过滤' (Filter).
- IO参数 (IO Parameters) Panel:** Located on the right, it has a tab for '算子参数' (Operator Parameters). Under the '默认替换方案' (Default Replacement Scheme) section, a dropdown menu is open, showing a list of replacement options: 'zero', 'minimum', 'maximum', 'average', 'value', 'median', and 'mode'. The 'zero' option is currently selected.
- 过滤条件 (Filter Conditions) Panel:** Also on the right, it features a dropdown menu for selecting filter conditions. The 'notMissing' option is selected and highlighted in blue. Other visible options include 'customFilters', 'notMissingLabels', and 'notMissingAttributes'. A red arrow points from the '过滤' (Filter) node on the canvas to this panel.

类别变量独热编码(onehot)

为什么要对类别变量重新编码？一个最简单的理解就是：**机器学习算法要求输入的变量值必须是数值。**

- 1、要能数字体现
- 2、要有语义




类别型变量 的值一般都是 **标签**，一般都是字符串存储，例如 Embarked（登船港口）它的取值是{ 'C' , 'Q' , 'S' }，这就需要把它重新编码为数值。但是能简单的使用 **1,2,3 对 C,Q,S 重新编码** 吗？显然不能，因为 C,Q,S 之间并没有数量关系，用1,2,3 来编码，算法就会认为 S 的值是 C 的值的 3 倍，这显然是错误的。即使有一些类别变量的标签值用数字来存储，但是同样的道理，我们不能认为它已经是数字了就不需要独热编码，不论类别变量的标签值是字符串还是数字，本质上它只是一个 **编号**。

类别变量独热编码(onehot)

针对类别型变量，我们必须重新编码，把它们转换为数值型变量，但是信息量还不会丢失。最常用的一种类别变量编码方式**哑变量 (Dummy Variables) 编码**，这是统计界的称呼，机器学习界喜欢叫**独热编码 (one-hot encoding)**。

独热编码就是把 1 个类别型变量转化为 N 个 0/1 标识变量。类别型变量有多少个类别值，转化后的 0/1 向量就有多少维。

用户ID	地区
C0001	北京
C0002	上海
C0003	广州
C0004	上海
C0005	广州
C0006	广州
C0007	北京
C0008	北京
C0009	北京
C0010	上海
C0011	上海
C0012	广州



one-hot编码
(独热编码)



用户ID	地区=北京	地区=上海	地区=广州
C0001	1	0	0
C0002	0	1	0
C0003	0	0	1
C0004	0	1	0
C0005	0	0	1
C0006	0	0	1
C0007	1	0	0
C0008	1	0	0
C0009	1	0	0
C0010	0	1	0
C0011	0	1	0
C0012	0	0	1

1.稀疏向量
2.等距思想



类别变量独热编码 (onehot) 的 Sophon 实现

Sophon 中, 我们首先使用“**字符串索引**”算子将类别索引成1,2,3...这样的数值,然后使用“**one-hot 编码**”算子进行独热编码.



类别变量独热编码 (onehot) 的 Python 实现

```
import pandas as pd
```

```
# 原始数据
```

```
data = {'颜色': ['红色', '蓝色', '绿色', '蓝色', '红色']}
```

```
df = pd.DataFrame(data)
```

```
# 独热编码
```

```
onehot_df = pd.get_dummies(df)
```

```
print(onehot_df)
```

	颜色_红色	颜色_蓝色	颜色_绿色
0	1	0	0
1	0	1	0
2	0	0	1
3	0	1	0
4	1	0	0

连续变量分箱

分箱，英文叫 **Binning**，这是一个有点专业的叫法，其实就是我们常说的 **变量分段**。例如 **年龄** 本来是连续型变量，现在我们把它分成 **5 个段**：**0-18** 岁一个段，**18-25** 一个段，**25-40** 一个段，**40-60** 一个段，**60+** 一个段。这就叫 **分箱**，有时候也叫 **分桶**，还可以叫 **变量离散化**


- **防止过拟合**：扔掉细微的差异信息
- **业务解释需要**：类似于成绩分优秀/良好/及格

顺德区教育局期末成绩“等级制”示意图



连续变量分箱方法

- **自定义分箱：**分箱的边界值自定义
- **等宽分箱：** 每一个箱的边界呈等差数列。例如以 10 为间隔对年龄分箱，那就是按照这样的区间来分箱： 0-10,10-20, 20-30...
- **等深分箱：** 保证每一个箱内记录数一样或者满足指定的比例。例如如果要分为 10 个箱，并且每个箱内的记录数要相等（即每个箱内都包含 10% 的记录）。



连续变量分箱: Sophon 实现

预处理

交互式预处理

清理

字符串

数值

日期

元信息

分箱

分位数离散化

MDLP分箱

chimerge

特征分箱

分位数离散化

IO参数 算子参数

无效值处理方法

skip

分箱数

2

相对误差

0.001

chimerge

IO参数 算子参数 高级参数

无效数据处理方式

skip

桶数

10

启发式因子

100.0

MDLP分箱

IO参数 算子参数

无效值处理方法

skip

最大桶数

10

停止条件

-0.1

特征分箱

IO参数 算子参数

无效值处理方法

skip

自定义分割数组

☒ 自动扩展左边界

☒ 自动扩展右边界

连续变量分箱: Python 实现

```
import pandas as pd
import numpy as np
# 生成一个随机的连续型变量示例
# 设置随机种子以便结果可重复
np.random.seed(0)
# 生成 100 个服从正态分布的年龄数据
data = pd.DataFrame({ 'Age': np.random.normal(loc=30, scale=10,
size=100)})
# 打印原始数据
print("原始数据: ")
print(data.head())
# 1) 等宽分箱
# 定义分箱边界
bins_width = [0, 18, 30, 50, 100]
# 分箱后的类别标签
```

```
labels_width = ['少年', '青年', '中年', '老年']
# 使用pandas.cut 进行等宽分箱 data['Age_binned_width'] =
pd.cut(data['Age'], bins=bins_width, labels=labels_width)
print("\n等宽分箱结果: ")
print(data[['Age', 'Age_binned_width']].head())

# 2) 等频分箱
# 定义分箱数量 (这里分成 4 个相等频率的箱)
num_bins = 4
# 使用pandas.qcut 进行等频分箱
data['Age_binned_freq'] = pd.qcut(data['Age'], q=num_bins,
duplicates='drop')

print("\n等频分箱结果: ")
print(data[['Age', 'Age_binned_freq']].head())
```

连续变量分箱: Python 实现 (输出)

原始数据		等宽分箱结果		等频分箱结果	
Age		Age	Age_binned_width	Age	Age_binned_freq
0 22.992718		0 22.992718	少年	0 22.992718	(10.964, 21.5]
1 35.287272		1 35.287272	中年	1 35.287272	(33.766, 47.7]
2 27.425060		2 27.425060	青年	2 27.425060	(21.5, 33.766]
3 22.017099		3 22.017099	少年	3 22.017099	(10.964, 21.5]
4 35.290562		4 35.290562	中年	4 35.290562	(33.766, 47.7]

标准化和归一化

标准化和归一化都属于对变量进行无量纲化处理的方法，目的就是为了使不同规格尺度的数据转换到同一规格尺度上。为什么要这么做？

- 无量纲化可以让不属于同一量纲的特征值可以比较：例如身高 (cm)，体重(kg)
- 无量纲化后模型收敛会加快（运行速度较快）
- 无量纲化对一些模型的结果影响较大，一般都是涉及到距离计算的模型和算法，例如 KNN，聚类分析，SVM 等。

特征1	特征2	特征3	特征4
90	2	10	40
60	4	15	45
75	3	13	46



特征1	特征2	特征3	特征4
1.	0.	0.	0.
0.	1.	1.	0.83
0.5	0.5	0.6	1.

归一化

归一化就是把原始的连续型变量转换为范围在【a-b】之间的变量，常见的 $a=0$ ， $b=1$ ，转换公式如下：

$$X' = \frac{x - \min}{\max - \min}$$

■ min表示 x 的最小值， max表示 x 的最大值

特征1	特征2	特征3	特征4	特征1	特征2	特征3	特征4
90	2	10	40	$\frac{90 - 60}{90 - 60}$	$\frac{2 - 2}{4 - 2}$	$\frac{10 - 10}{15 - 10}$	$\frac{40 - 40}{46 - 40}$
60	4	15	45	$\frac{60 - 60}{90 - 60}$	$\frac{4 - 2}{4 - 2}$	$\frac{15 - 10}{15 - 10}$	$\frac{45 - 40}{46 - 40}$
75	3	13	46	$\frac{75 - 60}{90 - 60}$	$\frac{3 - 2}{4 - 2}$	$\frac{13 - 10}{15 - 10}$	$\frac{46 - 40}{46 - 40}$

注：里面是第一步，还需要第二步乘以 $(1-0)+0$

归一化

我们需要使用 `sklearn.preprocessing.MinMaxScaler()` 方法来进行归一化：

```
1 from sklearn import preprocessing
2 # 实例化一个归一化转换器
3 minmaxscaler = preprocessing.MinMaxScaler()
4 # 使用 Age 变量的数据训练一个归一化转换模型
5 minmaxscaler.fit(titanic_df[['Age']])
6 # Age 归一化处理后保存为原数据对象中的新变量 Age_normal
7 titanic_df['Age_normal'] = minmaxscaler.transform(titanic_df[['Age']])
8 # 查看归一化后的数据
9 titanic_df.head()
```

	Survived	Pclass	Sex	Age	SibSp	Parch	Fare	Cabin	Embarked	Age_isna	Age_bin	Age_wbin	Age_dbin	Age_std	Age_normal
0	0	3	male	22.0	1	0	7.2500	NaN	S	0	(18, 25]	(16.336, 24.294]	(20.0, 28.0]	-0.597055	0.271174
1	1	1	female	38.0	1	0	71.2833	C85	C	0	(25, 40]	(32.252, 40.21]	(30.0, 38.0]	0.634162	0.472229
2	1	3	female	26.0	0	0	7.9250	NaN	S	0	(25, 40]	(24.294, 32.252]	(20.0, 28.0]	-0.289251	0.321438
3	1	1	female	35.0	1	0	53.1000	C123	S	0	(25, 40]	(32.252, 40.21]	(30.0, 38.0]	0.403309	0.434531
4	0	3	male	35.0	0	0	8.0500	NaN	S	0	(25, 40]	(32.252, 40.21]	(30.0, 38.0]	0.403309	0.434531

标准化


标准化要做的事情就是把原始的连续型变量转换为 **均值为 0，标准差为 1** 的变量，转换公式如下：

$$X' = \frac{x - \text{mean}}{\sigma}$$

■ mean表示 x 的均值，σ表示 x 的标准差

标准化和归一化比较

- 对于归一化来说：如果出现异常点，影响了最大值和最小值，那么结果显然会发生改变
- 对于标准化来说：如果出现异常点，由于具有一定数据量，少量的异常点对于平均值的影响并不大，从而方差改变较小。
- 因此**标准化更常用**！



$$X' = \frac{x - \min}{\max - \min}$$

$$X' = \frac{x - \text{mean}}{\sigma}$$

sophon实现标准化和归一化



3 MaxAbsScaler (最大绝对值归一化)

$$d'_i = d_i / |max|$$

利用样本的最大值作为参照，按比例缩放样本。



6 chapter

特征变量的构造和组合

泰坦尼克案例中，原始数据集 train.csv 只有 12 个变量，之前的章节，我们都是基于这个 12 个变量来进行的探索分析和数据预处理。现在我们要讨论的问题是：能否 **基于这 12 个原始变量构造出来更多的新变量**。答案当然是可以的！

接下来我们就来讲解一下如何基于已有变量构造新的衍生变量的方法，一般来说，有几种常用的新变量构造方法：

- **多个变量之间的数学运算**，例如构造一个新变量 $z=a/b$
- **基于逻辑判断来构造衍生变量**，形如 SQL 中的 case when ... then ... 这样的方式
- **多个特征变量进行组合**，例如性别，年龄本来是两个独立的变量，可以把他们组合起来变成新的独热编码变量：男&(0,18]，男&(18,25]...

变量构造 非常重要，**对应用机器学习来说，最重要的工作往往不是选择哪个算法，而是你能否构造出对目标变量有强预测能力的变量**

基于逻辑判断来构造新变量

例如，我们可以这样来构造一些新变量：

- 构造一个新变量 **IsAlone**（是否独自一人），规则是：如果 FamilySize=1，那么 IsAlone=1，否则 IsAlone=0
- 构造一个新变量 **IsMother**（是否是母亲），规则是：如果性别是女性，父母/子女数大于 0，并且年龄大于 20 岁，那么 IsMother=1，否则 IsMother=0

多个特征变量进行交叉

多个特征变量进行交叉，例如**性别**，**年龄**本来是两个独立的变量，可以把他们交叉起来变成新的独热编码变量：男&(0,18]，男&(18,25]。。。 **特征组合要求特征都必须是类别型的**，所以我们先对**年龄**变量进行分箱。


小结

本节我们介绍了三种常用的特征构造的方法：

- 基于变量之间的数学运算构造新变量
- 基于规则构造新变量
- 两个类别型变量进行组合

特征构造可以说是应用机器学习最重要的工作，特征构造的好坏直接决定了模型的好坏。有句话是这样说的：**数据决定了模型的上限，算法只不过是无限逼近这个上限而已**，可见特征构造的重要性。







Q&A

TRANSWARP
星环科技