

EM 算法

2025年5月

TRANSWARP
星环科技



目录 >

CONTENTS

- 1 参数估计方法
- 2 EM 算法思想
- 3 GMM 模型

1
chapter

参数估计方法

最大似然估计 (Maximum Likelihood Estimation, MLE)

MLE 就是利用已知的样本结果，反推最有可能(最大概率)导致这样结果的参数值的计算过程。

直白来讲，就是给定了一定的数据，假定知道数据是从某种分布中随机抽取出来的，但是不知道这个分布具体的参数值，即“模型已定，参数未知”，MLE 就可以用来估计模型的参数。

MLE 的目标是找出一组参数（模型中的参数），使得模型产出观察数据的概率最大。

$$\arg \max_{\theta} p(X; \theta)$$

最大似然估计(MLE)

假定盒子中有黑白两种球，数目未知，黑白球比例也未知，现只知道随机的十次有放回的抽样情况，求各个盒子中抽取出白球的概率？

盒子编号	1	2	3	4	5	6	7	8	9	10
1	黑	黑	黑	黑	黑	黑	黑	黑	黑	黑
2	黑	黑	白	白	黑	黑	黑	白	黑	黑
3	黑	白	黑	黑	白	黑	白	黑	白	白
4	白	黑	白	白	黑	白	黑	白	白	白
5	白	白	白	白	白	白	白	白	白	白

最大似然估计(MLE)

MLE 求解过程

- 编写似然函数(即联合概率函数)<似然函数：在样本固定的情况下，样本出现的概率与参数 θ 之间的函数>；
- 对似然函数取对数，并整理；(一般都进行)
- 求导数；
- 解似然方程。

$$L(X; \theta) \rightarrow l(\theta) = \ln(L(X; \theta)) \rightarrow \frac{\partial l}{\partial \theta}$$
$$\arg \max_p P(x_i; p) = \arg \max_p \ln(P(x_i; p))$$

最大似然估计(MLE)

- 盒子中只有黑球和白球，假定白球的比例为 p ，那么黑球的比例为 $1-p$ 。因为采取的是有放回的随机抽取，那么每次抽取出来的球的颜色服从同一独立分布情况，即每次抽取之间是独立互不影响的。

$$L(X; p) = P(x_1, x_2, x_3, x_4, x_5, x_6, x_7, x_8, x_9, x_{10}; p) = \prod_{i=1}^{10} P(x_i; p)$$

$$l(p) = \ln(L(X; p)) = \sum_{i=1}^{10} \ln P(x_i; p)$$

$$\frac{\partial l}{\partial p} = 0 \rightarrow p = ?$$

最大似然估计(MLE)

- 盒子1中抽取出白球的概率:

$$L(X; p) = (1-p)^{10} \quad l(p) = 10 \ln(1-p) \xrightarrow{0 \leq p \leq 1} p = 0$$

- 盒子2中抽取出白球的概率:

$$L(X; p) = p^3(1-p)^7 \quad l(p) = 3 \ln p + 7 \ln(1-p) \quad \frac{\partial l}{\partial p} = \frac{3}{p} - \frac{7}{1-p}$$

- 盒子3中抽取出白球的概率:

$$\xrightarrow{\frac{\partial l}{\partial p}=0} p = 0.3$$

$$L(X; p) = p^5(1-p)^5 \quad l(p) = 5 \ln p + 5 \ln(1-p) \quad \frac{\partial l}{\partial p} = \frac{5}{p} - \frac{5}{1-p}$$

$$\xrightarrow{\frac{\partial l}{\partial p}=0} p = 0.5$$

最大似然估计(MLE)

- 盒子4中抽取白球的概率:

$$L(X; p) = p^7 (1-p)^3 \quad l(p) = 7 \ln p + 3 \ln(1-p) \quad \frac{\partial l}{\partial p} = \frac{7}{p} - \frac{3}{1-p}$$
$$\xrightarrow{\frac{\partial l}{\partial p} = 0} p = 0.7$$

- 盒子5中抽取白球的概率:

$$L(X; p) = p^{10} \quad l(p) = 10 \ln p \quad \xrightarrow{0 \leq p \leq 1} p = 1$$

盒子编号	白球	黑球
1	0	1
2	0.3	0.7
3	0.5	0.5
4	0.7	0.3
5	1	0

贝叶斯算法估计

- 贝叶斯算法估计是一种根据**先验概率**和**样本数据**来计算后验概率的方法。
- 贝叶斯算法中的常见概念：
 - $P(A)$ 是事件 A 的先验概率或边缘概率。
 - $P(A|B)$ 是在事件 B 发生的条件下，事件 A 发生的条件概率，也称为 A 的后验概率。
 - $P(B|A)$ 是在事件 A 发生的条件下，事件 B 发生的条件概率，也称为似然函数（Likelihood）。
 - $P(B)$ 是事件 B 的先验概率或边缘概率。

$$P(AB) = P(A)P(B|A) = P(B)P(A|B) \Rightarrow P(A|B) = \frac{P(A)P(B|A)}{P(B)}$$

$$P(A_i|B) = \frac{P(B|A_i)P(A_i)}{\sum_j P(B|A_j)P(A_j)} \quad f(\theta|x) = \frac{f(x|\theta)g(\theta)}{\int_{\theta' \in \Theta} f(x|\theta')g(\theta')}$$

贝叶斯算法估计

- 现在有五个盒子，假定每个盒子中都有黑白两种球，并且黑白球的比例如下；现已知从这五个盒子中的任意一个盒子中有放回的抽取两个球，且均为白球，问这两个球是从哪个盒子中抽取出来的？

盒子编号	白球(p)	黑球(q)
1	0	1
2	0.3	0.7
3	0.5	0.5
4	0.7	0.3
5	1	0

贝叶斯算法估计

- 使用 **MLE**（最大似然估计），结论是从第五个盒子抽取的球：

$$L(X; p) = p^2 \xrightarrow[p]{\arg \max L(X; p)} p = 1$$

- 使用贝叶斯算法估计，结论是从第五个盒子抽取的球：**假定抽出白球为事件 B，从第 i 个盒子中抽取为事件 A_i。**

$$P(A_1|B) = \frac{P(A_1)P(B|A_1)}{P(B)} = \frac{0.2 * 0}{0.5} = 0$$

$$P(A_2|B) = 0.12 \quad P(A_3|B) = 0.2$$

$$P(A_4|B) = 0.28 \quad P(A_5|B) = 0.4$$

盒子编号	白球(p)	黑球(q)
1	0	1
2	0.3	0.7
3	0.5	0.5
4	0.7	0.3
5	1	0

	1	2	3	4	5
P(A)	0.2	0.2	0.2	0.2	0.2

贝叶斯算法估计

- 现在不是从五个盒子中任选一个盒子进行抽取，而是按照一定的概率选择对应的盒子，概率如下。假定抽出白球为事件B，从第i个盒子中抽取为事件A_i。结论是从第四个盒子抽取的球。

$$P(A_1|B) = \frac{P(A_1)P(B|A_1)}{P(B)} = \frac{0.2 * 0}{0.54} = 0$$

$$P(A_2|B) = 0.11 \quad P(A_3|B) = 0.19$$

$$P(A_4|B) = 0.52 \quad P(A_5|B) = 0.19$$

盒子编号	白球(p)	黑球(q)
1	0	1
2	0.3	0.7
3	0.5	0.5
4	0.7	0.3
5	1	0

	1	2	3	4	5
P(A)	0.1	0.2	0.2	0.4	0.1

最大后验概率估计(MAP)

- MAP 和 MLE 一样，都是通过样本估计参数 θ 的值；在 MLE 中，是使似然函数 $P(x|\theta)$ 最大的时候参数 θ 的值，MLE 中假设先验概率是一个等值的；而在 MAP 中，则是求 θ 使 $P(x|\theta)P(\theta)$ 的值最大，这也就是要求 θ 值不仅仅是让似然函数最大，同时要求 θ 本身出现的先验概率也得比较大。
- 可以认为 MAP 是贝叶斯算法的一种应用

$$P(\theta'|X) = \frac{P(\theta')P(X|\theta')}{P(X)} \rightarrow \arg \max_{\theta'} P(\theta'|X) \rightarrow \arg \max_{\theta'} P(\theta')P(X|\theta')$$

The background features a complex network diagram with numerous nodes (represented by small grey and black dots) connected by thin, light grey lines. These connections form a dense web that fills the entire frame, with some areas appearing more concentrated than others. The overall aesthetic is technical and modern, typical of data science or machine learning presentations.

2 chapter

EM 算法思想

EM算法

- EM 算法 (Expectation Maximization Algorithm, 最大期望算法) 是一种迭代类型的算法, 是一种在概率模型中寻找参数最大似然估计或者最大后验估计的算法, 其中概率模型依赖于无法观测的隐藏变量。
- EM 算法流程:
 - ◆ 初始化分布参数
 - ◆ 重复下列两个操作直到收敛:
 - E 步骤: 估计隐藏变量的概率分布期望函数;
 - M 步骤: 根据期望函数重新估计分布参数。

EM算法原理

- 给定的m个训练样本 $\{x^{(1)}, x^{(2)}, \dots, x^{(m)}\}$ ，样本间独立，找出样本的模型参数 θ ，极大化模型分布的对数似然函数如下：


$$\theta = \arg \max_{\theta} \sum_{i=1}^m \log(P(x^{(i)}; \theta))$$

- 假定样本数据中存在隐含数据 $z \{z^{(1)}, z^{(2)}, \dots, z^{(m)}\}$ ，此时极大化模型分布的对数似然函数如下：

$$\begin{aligned} \theta &= \arg \max_{\theta} \sum_{i=1}^m \log(P(x^{(i)}; \theta)) \\ &= \arg \max_{\theta} \sum_{i=1}^m \log\left(\sum_{z^{(i)}} P(z^{(i)}) P(x^{(i)} | z^{(i)}; \theta)\right) \\ &= \arg \max_{\theta} \sum_{i=1}^m \log\left(\sum_{z^{(i)}} P(x^{(i)}, z^{(i)}; \theta)\right) \end{aligned}$$

EM算法原理

■ 令 z 的分布为 $Q(z;\theta)$ ，并且 $Q(z;\theta) \geq 0$ ；那么有如下公式： $\sum Q(z;\theta) = 1$




$$\begin{aligned} l(\theta) &= \sum_{i=1}^m \log \sum_z p(x, z; \theta) \\ &= \sum_{i=1}^m \log \sum_z Q(z; \theta) \cdot \frac{p(x, z; \theta)}{Q(z; \theta)} \\ &= \sum_{i=1}^m \log \left(E_Q \left(\frac{p(x, z; \theta)}{Q(z; \theta)} \right) \right) \\ &\geq \sum_{i=1}^m E_Q \left(\log \left(\frac{p(x, z; \theta)}{Q(z; \theta)} \right) \right) \\ &= \sum_{i=1}^m \sum_z Q(z; \theta) \log \left(\frac{p(x, z; \theta)}{Q(z; \theta)} \right) \end{aligned}$$

Jensen不等式

- 如果函数 f 为凸函数，那么存在下列公式：

$$f(\theta x + (1 - \theta)y) \leq \theta f(x) + (1 - \theta)f(y)$$



- 若 $\theta_1, \dots, \theta_k \geq 0$, $\theta_1 + \dots + \theta_k = 1$; 则

$$f(\theta_1 x_1 + \dots + \theta_k x_k) \leq \theta_1 f(x_1) + \dots + \theta_k f(x_k)$$

$$f(E(x)) \leq E(f(x))$$

EM算法原理

- 根据Jensen不等式的特性，当下列式子的值为常数的时候， $l(\theta)$ 函数才能取等号。

$$\frac{p(x, z; \theta)}{Q(z; \theta)} = c$$

$$l(\theta) \geq \sum_{i=1}^m \sum_z Q(z; \theta) \log \left(\frac{p(x, z; \theta)}{Q(z; \theta)} \right)$$

$$Q(z, \theta) = \frac{p(x, z; \theta)}{c} = \frac{p(x, z; \theta)}{c \cdot \sum_{z^i} Q(z^i; \theta)}$$


$$\sum_z Q(z; \theta) = 1$$

$$= \frac{p(x, z; \theta)}{\sum_{z^i} c \cdot Q(z^i; \theta)} = \frac{p(x, z; \theta)}{\sum_{z^i} p(x, z^i; \theta)} = \frac{p(x, z; \theta)}{p(x; \theta)} = p(z | x; \theta)$$

EM算法原理

$$\begin{aligned}\theta &= \arg \max_{\theta} l(\theta) = \arg \max_{\theta} \sum_{i=1}^m \sum_z Q(z; \theta) \log \left(\frac{p(x, z; \theta)}{Q(z; \theta)} \right) \\ &= \arg \max_{\theta} \sum_{i=1}^m \sum_z Q(z | x; \theta) \log \left(\frac{p(x, z; \theta)}{Q(z | x; \theta)} \right) \\ &= \arg \max_{\theta} \sum_{i=1}^m \sum_z Q(z | x; \theta) \log(p(x, z; \theta))\end{aligned}$$

EM算法原理



EM算法原理

- 样本数据 $x=\{x_1, x_2, \dots, x_n\}$, 联合分布 $p(x, z; \theta)$, 条件分布 $p(z|x; \theta)$, 最大迭代次数 J 1) 随机初始化模型参数 θ 的初始值 θ^0 2) 开始EM算法的迭代处理:

- E步: 计算联合分布的条件概率期望

$$Q^j = p(z|x; \theta^j) \quad l(\theta) = \sum_{i=1}^m \sum_z Q^j \log(p(x, z; \theta^j))$$

- M步: 极大化L函数, 得到 θ^{j+1}

$$\theta^{j+1} = \arg \max_{\theta} l(\theta)$$

- 如果 θ^{j+1} 已经收敛, 则算法结束, 输出最终的模型参数 θ , 否则继续迭代处理

EM算法直观案例

- 假设现有两个装有不定数量黑球、白球的盒子，随机从盒子中抽取出一个白球的概率分布为 p_1 和 p_2 ；为了估计这两个概率，每次选择一个盒子，有放回的连续随机抽取5个球，记录如下：

盒子编号	1	2	3	4	5	统计
1	白	白	黑	白	黑	3白-2黑
2	黑	黑	白	白	黑	2白-3黑
1	白	黑	黑	黑	黑	1白-4黑
2	白	黑	白	黑	白	3白-2黑
1	黑	白	黑	白	黑	2白-3黑

EM算法直观案例

- 使用 MLE 最大似然估计:

$$l(p_1) = \log(p_1^6(1-p_1)^9) = 6\log p_1 + 9\log(1-p_1)$$
$$\frac{\partial l(p_1)}{\partial p_1} = \frac{6}{p_1} - \frac{9}{1-p_1} \xrightarrow{\text{令 } \frac{\partial l(p_1)}{\partial p_1} = 0} p_1 = 0.4$$

$$l(p_2) = \log(p_2^5(1-p_2)^5) = 5\log p_2 + 5\log(1-p_2)$$
$$\frac{\partial l(p_2)}{\partial p_2} = \frac{5}{p_2} - \frac{5}{1-p_2} \xrightarrow{\text{令 } \frac{\partial l(p_2)}{\partial p_2} = 0} p_2 = 0.5$$

EM算法直观案例

- 如果现在不知道具体的盒子编号，但是同样还是为了求解 p_1 和 p_2 的值，这个时候就相当于多了一个隐藏变量 z ， z 表示的是每次抽取的时候选择的盒子编号，比如 z_1 就表示第一次抽取的时候选择的是盒子1还是盒子2。

盒子编号	1	2	3	4	5	统计
z_1	白	白	黑	白	黑	3白-2黑
z_2	黑	黑	白	白	黑	2白-3黑
z_3	白	黑	黑	黑	黑	1白-4黑
z_4	白	黑	白	黑	白	3白-2黑
z_5	黑	白	黑	白	黑	2白-3黑

EM算法直观案例

- 随机初始一个概率值： $p_1=0.1$ 和 $p_2=0.9$ ； 然后使用最大似然估计计算每轮操作中从两个盒子中抽取的最大概率。 然后计算出来的 z 值， 重新使用极大似然估计法则估计概率值。

$$L(z_1 = 1|x; p_1) = 0.1^3 * 0.9^2 = 0.00081$$

$$L(z_1 = 2|x; p_2) = 0.9^3 * 0.1^2 = 0.00729$$

$$p_1 = \frac{1}{3}; p_2 = 0.6$$

轮数	盒子1	盒子2
1	0.00081	0.00729
2	0.00729	0.00081
3	0.06561	0.00009
4	0.00081	0.00729
5	0.00729	0.00081

轮数	盒子1	盒子2
1	0.01565	0.03456
2	0.0313	0.02304
3	0.0626	0.01536
4	0.01565	0.03456
5	0.0313	0.02304

EM算法直观案例

- 使用最大似然概率法则估计 z 和 p 的值，但是在这个过程中，只使用一个最有可能的值。如果考虑所有的 z 值，然后对每一组 z 值都估计一个概率 p ，那么这个时候估计出来的概率可能会更好，可以用期望的方式来简化这个操作。

轮数	盒子1	盒子2
1	0.00081	0.00729
2	0.00729	0.00081
3	0.06561	0.00009
4	0.00081	0.00729
5	0.00729	0.00081

轮数	盒子1概率	盒子2概率
1	0.1	0.9
2	0.9	0.1
3	0.999	0.001
4	0.1	0.9
5	0.9	0.1

EM算法直观案例

■ 以 p_1 估计为例，计算如下：

$$Q^j = p(z|x; \theta^j) \quad l(\theta) = \sum_{i=1}^m \sum_z Q^j \log(p(x, z; \theta^j))$$

$$l(p_1) = \log(p_1^{5.199} (1-p_1)^{9.796}) = 5.199 \log p_1 + 9.796 \log(1-p_1)$$

$$\frac{\partial l(p_1)}{\partial p_1} = \frac{5.199}{p_1} - \frac{9.796}{1-p_1} \xrightarrow{\text{令 } \frac{\partial l(p_1)}{\partial p_1} = 0} p_1 = 0.347$$

盒子1概率	盒子2概率
0.1	0.9
0.9	0.1
0.999	0.001
0.1	0.9
0.9	0.1

轮数	盒子1白球	盒子1黑球
1	0.3	0.2
2	1.8	2.7
3	0.999	3.996
4	0.3	0.2
5	1.8	2.7
总计	5.199	9.796

统计
3白-2黑
2白-3黑
1白-4黑
3白-2黑
2白-3黑

EM算法直观案例

- 计算出 p_1 和 p_2 的概率值后，再次计算从每个盒子中抽取的概率如下：

$$p_1 = 0.347 \quad p_2 = 0.58$$

轮数	盒子1	盒子2
1	0.0178	0.0344
2	0.0335	0.0249
3	0.063	0.018
4	0.0178	0.0344
5	0.0335	0.0249

轮数	盒子1概率	盒子2概率
1	0.34	0.66
2	0.57	0.43
3	0.78	0.22
4	0.34	0.66
5	0.57	0.43

EM算法直观案例

- 再次计算概率值如下：

$$p_1 = 0.392 \quad p_2 = 0.492$$

轮数	盒子1白球	盒子1黑球
1	1.02	0.68
2	1.14	1.71
3	0.78	3.12
4	1.02	0.68
5	1.14	1.71
总计	5.1	7.9

轮数	盒子2白球	盒子2黑球
1	1.98	1.32
2	0.86	1.29
3	0.22	0.88
4	1.98	1.32
5	0.86	1.29
总计	5.9	6.1

EM算法收敛证明

- EM算法的收敛性只要我们能够证明对数似然函数的值在迭代的过程中是增加的即可

$$\sum_{i=1}^m \log(p(x^i; \theta^{j+1})) \geq \sum_{i=1}^m \log(p(x^i; \theta^j))$$

EM算法收敛证明

$$L(\theta, \theta^j) = \sum_{i=1}^m \sum_z p(z|x^i; \theta^j) \log p(x^i, z; \theta)$$

$$H(\theta, \theta^j) = \sum_{i=1}^m \sum_z p(z|x^i; \theta^j) \log p(z|x^i; \theta)$$

$$L(\theta, \theta^j) - H(\theta, \theta^j) = \sum_{i=1}^m \log(x^i; \theta)$$

$$\begin{aligned} & [L(\theta^{j+1}, \theta^j) - L(\theta^j, \theta^j)] - [H(\theta^{j+1}, \theta^j) - H(\theta^j, \theta^j)] \\ &= \sum_{i=1}^m \log(x^i; \theta^{j+1}) - \sum_{i=1}^m \log(x^i; \theta^j) \end{aligned}$$

EM算法收敛证明

$$L(\theta^{j+1}, \theta^j) - L(\theta^j, \theta^j) \geq 0 \quad L(\theta, \theta^j) = \sum_{i=1}^m \sum_z p(z|x^i; \theta^j) \log p(x^i, z; \theta)$$

$$H(\theta^{j+1}, \theta^j) - H(\theta^j, \theta^j) = \sum_{i=1}^m \sum_z p(z|x^i; \theta^j) \log \frac{p(z|x^i; \theta^{j+1})}{p(z|x^i; \theta^j)}$$

$$H(\theta, \theta^j) = \sum_{i=1}^m \sum_z p(z|x^i; \theta^j) \log p(z|x^i; \theta) \leq \sum_{i=1}^m \log \left(\sum_z p(z|x^i; \theta^j) \cdot \frac{p(z|x^i; \theta^{j+1})}{p(z|x^i; \theta^j)} \right) = 0$$

$$\sum_{i=1}^m \log (x^i; \theta^{j+1}) - \sum_{i=1}^m \log (x^i; \theta^j) \geq 0$$

问题

- 随机选择1000名用户，测量用户的身高；若样本中存在男性和女性，身高分别服从高斯分布 $N(\mu_1, \sigma_1)$ 和 $N(\mu_2, \sigma_2)$ 的分布，试估计参数： $\mu_1, \sigma_1, \mu_2, \sigma_2$ ；如果明确的知道样本的情况(即男性和女性数据是分开的)，那么我们使用极大似然估计来估计这个参数值。如果样本是混合而成的，不能明确的区分开，那么就没法直接使用极大似然估计来进行参数的估计啦。


1
3
chapter

GMM 模型



GMM

- GMM (Gaussian Mixture Model, 高斯混合模型) 是指该算法由多个高斯模型线性叠加混合而成。每个高斯模型称之为 **component**。GMM 算法描述的是数据的本身存在的一种分布。
- GMM 算法常用于聚类应用中，component的个数就可以认为是类别的数量。
- 假定 GMM 由 k 个 Gaussian 分布线性叠加而成，那么概率密度函数如下：

$$p(x) = \sum_{k=1}^K p(k)p(x|k) = \sum_{k=1}^K \pi_k p(x; \mu_k, \Sigma_k)$$




GMM




K-means VS GMM

- K-means 预测类别 **onehot 标签**
- GMM 预测类别 **概率分布**

K-means [0,0,1]




GMM [0.01,0.19,0.8]




K-means VS GMM

- K-means 硬的EM (阉割版EM)
- GMM 软的EM (完美版EM)

K-means



GMM



GMM

■ 对数似然函数

$$l(\pi, \mu, \sigma) = \sum_{i=1}^N \log \left(\sum_{k=1}^K \pi_k p(x^i; \mu_k, \Sigma_k) \right)$$

GMM-EM算法求解 E step

$$w_j^{(i)} = Q_i(z^{(i)} = j) = p(z^{(i)} = j | x^{(i)}; \pi, \mu, \Sigma)$$

GMM-EM算法求解 E step

$$\begin{aligned}
l(\pi, \mu, \Sigma) &= \sum_{i=1}^m \sum_{z^{(i)}} Q_i(z^{(i)}) \log \left(\frac{p(x^{(i)}, z^{(i)}; \pi, \mu, \Sigma)}{Q_i(z^{(i)})} \right) \\
&= \sum_{i=1}^m \sum_{j=1}^k Q_i(z^{(i)} = j) \log \frac{p(x^{(i)} | z^{(i)} = j; \mu, \Sigma) \cdot p(z^{(i)} = j; \pi)}{Q_i(z^{(i)} = j)} \\
&= \sum_{i=1}^m \sum_{j=1}^k w_j^{(i)} \log \left(\frac{\frac{1}{(2\pi)^{\frac{n}{2}} |\Sigma_j|^{\frac{1}{2}}} e^{-\frac{1}{2}(x^{(i)} - \mu_j)^T \Sigma_j^{-1} (x^{(i)} - \mu_j)}}{w_j^{(i)}} \right) \cdot \pi_j
\end{aligned}$$

GMM-EM算法求解 对均值求偏导

$$l(\pi, \mu, \Sigma) = \sum_{i=1}^m \sum_{j=1}^k w_j^{(i)} \left(-\frac{1}{2} (x^{(i)} - \mu_j)^T \Sigma_j^{-1} (x^{(i)} - \mu_j) \right) + c$$

$$\frac{\partial l}{\partial \mu_l} = -\frac{1}{2} \sum_{i=1}^m w_l^{(i)} \left(x^{(i)T} \Sigma_l^{-1} x^{(i)} - x^{(i)T} \Sigma_l^{-1} \mu_l - \mu_l^T \Sigma_l^{-1} x^{(i)} + \mu_l^T \Sigma_l^{-1} \mu_l \right)$$

$$= \frac{1}{2} \sum_{i=1}^m w_l^{(i)} \left(\left(x^{(i)T} \Sigma_l^{-1} \right)^T + \Sigma_l^{-1} x^{(i)} - \left(\left(\Sigma_l^{-1} \right)^T + \Sigma_l^{-1} \right) \mu_l \right)$$

$$= \sum_{i=1}^m w_l^{(i)} \left(\Sigma_l^{-1} x^{(i)} - \Sigma_l^{-1} \mu_l \right)$$

GMM-EM算法求解 对均值求偏导

$$\frac{\partial l}{\partial \mu_l} = \sum_{i=1}^m w_l^{(i)} (\Sigma_l^{-1} x^{(i)} - \Sigma_l^{-1} \mu_l)$$
$$\xrightarrow{\text{令 } \frac{\partial l}{\partial \mu_l} = 0} \mu_l = \frac{\sum_{i=1}^m w_l^{(i)} x^{(i)}}{\sum_{i=1}^m w_l^{(i)}}$$

GMM-EM算法求解 对方差求偏导

$$l(\pi, \mu, \Sigma) = \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^k w_j^{(i)} \left(\log \Sigma_j^{-1} - (x^{(i)} - \mu_j)^T \Sigma_j^{-1} (x^{(i)} - \mu_j) \right) + c$$

$$\frac{\partial l}{\partial \Sigma_l} = \frac{1}{2} \sum_{i=1}^m w_l^{(i)} \left(\Sigma_l - (x^{(i)} - \mu_l)(x^{(i)} - \mu_l)^T \right)$$

$$\xrightarrow{\text{令 } \frac{\partial l}{\partial \Sigma_l} = 0} \Sigma_l = \frac{\sum_{i=1}^m w_l^{(i)} (x^{(i)} - \mu_l)(x^{(i)} - \mu_l)^T}{\sum_{i=1}^m w_l^{(i)}}$$

对概率使用拉格朗日乘子法求解


$$l(\pi, \mu, \Sigma) = \sum_{i=1}^m \sum_{j=1}^k w_j^{(i)} \log \pi_j + c \quad s.t.: \sum_{j=1}^k \pi_j = 1$$

$$L(\pi) = \sum_{i=1}^m \sum_{j=1}^k w_j^{(i)} \log \pi_j + \beta \left(\sum_{j=1}^k \pi_j - 1 \right)$$

$$\frac{\partial L}{\partial \pi_l} = \sum_{i=1}^m \frac{w_l^{(i)}}{\pi_l} + \beta \xrightarrow{\text{令 } \frac{\partial L}{\partial \pi_l} = 0} \begin{aligned} \beta &= - \sum_{i=1}^m \sum_{j=1}^k w_j^{(i)} = -m \\ \pi_l &= \frac{1}{m} \sum_{i=1}^m w_l^{(i)} \end{aligned}$$

案例一：EM分类初识


■ 使用 EM 算法做分类问题



案例二：GMM 算法分类及参数选择案例

■ GMM 算法分类及参数选择

```
gmm = GaussianMixture(n_components=2, covariance_type='full', random_state=28)  
gmm.fit(x, y)
```



EM 算法是一个聚类算法

A. 正确

B. 错误

EM 算法中并没有用到极大似然估计

- A. 正确
- B. 错误

高斯混合模型 (GMM) 的极大似然估计 (MLE)

- A. 只能得到非退化 (协方差矩阵正定) 的局部最优解
- B. 存在非退化的全局最优解
- C. 解情况依赖于数据分布

EM 算法可用于生成式模型还是判别式模型？

- A. 生成式
- B. 判别式

假如你使用 EM 算法对一个有潜变量的模型进行最大似然估计 (Maximum likelihood estimate)。这时候要求你将算法进行修改, 使得其能找到最大后验分布 (Maximum a Posteriori estimation, MAP), 你需要修改算法的哪个步骤?

- A. Expectation
- B. Maximization**
- C. 不需要修改
- D. 都需要修改



Q&A

TRANSWARP
星环科技